Analisis Faktor-Faktor yang Mempengaruhi Pengunduran Diri Karyawan

Miyatunisa Putri Samma [25%], Uswatun Hasanah [25%], Syafiqah Marsya Kholiyadi [25%], Ahnaf Dzakwan A. [25%].

Universitas Islam Negeri Syarif Hidayatullah Jakarta

ABSTRACT *This study analyses the factors that influence employee resignation decisions using secondary data from publicly available employee datasets. The response variable in this study is the employee's decision to leave, while the predictor variables include job satisfaction level, performance evaluation, number of projects, average monthly working hours, length of service, work accident, promotion in the last five years, department, and salary level. Logistic regression models, both simple and multiple, were applied to identify the relationship between these variables. Variable selection was performed using t and chi-square tests to ascertain significance on the response variable. The results showed that the model with variable interactions provided better predictions than the model without interactions. Further analysis revealed that factors such as job satisfaction level, number of projects, and salary level have a significant influence on the probability of an employee resigning.*

Keywords*: Employee Resignation, Logistic Regression, Job Satisfaction*

ABSTRAK. Penelitian ini menganalisis faktor-faktor yang memengaruhi keputusan pengunduran diri karyawan dengan menggunakan data sekunder dari dataset karyawan yang tersedia secara publik. Variabel respon dalam penelitian ini adalah keputusan karyawan untuk keluar (left), sedangkan variabel prediktor meliputi tingkat kepuasan kerja, evaluasi kinerja, jumlah proyek, rata-rata jam kerja bulanan, lama bekerja, kecelakaan kerja, promosi dalam lima tahun terakhir, departemen, dan tingkat gaji. Model regresi logistik, baik sederhana maupun berganda, diterapkan untuk mengidentifikasi hubungan antara variabel-variabel tersebut. Seleksi variabel dilakukan menggunakan uji t dan chi-square untuk memastikan signifikansi terhadap variabel respon. Hasil penelitian menunjukkan bahwa model dengan interaksi variabel memberikan prediksi yang lebih baik dibandingkan model tanpa interaksi. Analisis lebih lanjut mengungkapkan bahwa faktor-faktor seperti tingkat kepuasan kerja, jumlah proyek, dan tingkat gaji memiliki pengaruh signifikan terhadap probabilitas karyawan mengundurkan diri.

Kata Kunci: Pengunduran Diri Karyawan, Regreri Logistik, Kepuasan Kerja

1. PENDAHULUAN

Pengunduran diri karyawan merupakan salah satu tantangan utama yang dihadapi oleh perusahaan. Tingginya tingkat pengunduran diri tidak hanya memengaruhi stabilitas operasional perusahaan, tetapi juga dapat meningkatkan biaya

perekrutan dan pelatihan bagi karyawan baru. Oleh karena itu, memahami faktor-faktor yang memengaruhi keputusan karyawan untuk mengundurkan diri menjadi sangat penting dalam konteks pengelolaan sumber daya manusia.

Penelitian ini bertujuan untuk menganalisis faktor-faktor yang memengaruhi keputusan pengunduran diri karyawan dengan menggunakan data sekunder dari dataset yang tersedia secara publik. Variabel respon dalam penelitian ini adalah keputusan karyawan untuk keluar dari perusahaan (left), yang bersifat biner (1 untuk keluar, 0 untuk tetap). Variabel prediktor yang dianalisis meliputi tingkat kepuasan kerja, evaluasi kinerja, jumlah proyek, rata-rata jam kerja bulanan, lama bekerja, kecelakaan kerja, promosi dalam lima tahun terakhir, departemen, dan tingkat gaji.

Metode regresi logistik digunakan untuk memprediksi probabilitas karyawan mengundurkan diri berdasarkan variabel-variabel tersebut. Seleksi variabel dilakukan menggunakan uji t dan chi-square untuk memastikan bahwa hanya variabel yang signifikan secara statistik yang dimasukkan ke dalam model. Selanjutnya, model dengan interaksi antar variabel diuji untuk mengevaluasi pengaruh gabungan dari beberapa faktor terhadap keputusan pengunduran diri.

2. METODE PENELITIAN

A. Data

Data yang digunakan dalam penulisan adalah data sekunder yang terdapat pada website berikut: https://www.kaggle.com/datasets/aminaidhm23386/employee-worker. Dataset ini berisi berbagai variabel yang diamati untuk memahami faktor-faktor yang mempengaruhi keputusan karyawan dalam meninggalkan perusahaan.

Dikarenakan penggunaan metode regresi logistik, maka penting untuk menentukan variabel respon (dependen) yang bersifat biner dan variabel prediktor (independen). Pada penelitian ini, variabel respon adalah left, yang menunjukkan apakah seorang karyawan keluar dari perusahaan (1) atau tetap bekerja (0). Sedangkan variabel prediktor dalah variabel yang mempengaruhi variabel respon. Pada penelitian ini, variabel prediktor meliputi: Tingkat kepuasan karyawan (satisfaction_level), Evaluasi kinerja terakhir (last_evaluation), Jumlah proyek (number_project), Jam kerja rata-rata per bulan (average_montly_hours), Lama bekerja (time_spend_company), Kecelakaan kerja (work_accident), Promosi dalam 5 tahun terakhir (promotion_last_5years), Departemen (sales), Gaji (salary).

Variabel	Deskripsi
satisfaction_level	Rating kepuasan karyawan
last_evaluation	Skor evaluasi kinerja terakhir
number_project	Jumlah proyek yang diselesaikan oleh karyawan
Average_montly_hours	Rata-rata jam kerja per-bulan
time_spend_company	Lama waktu (tahun) bekerja di perusahaan
Work_accident	Indikator adanya kecelakaan kerja (1 untuk ya, 0 untuk tidak)
left	Indikator apakah karyawan meninggalkan perusahaan(1 untuk ya, 0 untuk tidak)
promotion_last_5years	Indikator apakah karyawan mendapatkan promosi dalam 5 tahun terakhir (1 untuk ya, 0 untuk tidak)
sales	Departemen tempat karyawan bekerja
salary	Tingkat gaji karyawan (contoh: low, medium, high)

Tabel 1. Deskripsi variabel data HR

B. Model Regresi Logistik

Model regresi logistik adalah metode yang digunakan untuk memprediksi probabilitas dari suatu peristiwa atau hasil berdasarkan satu atau lebih variabel respon. Model ini sering digunakan dalam analisis data dengan variabel dependen yang bersifat biner (seperti 'ya' dan'tidak, atau 0 dan 1). Terdapat dua tipe model regresi logistik, yaitu;

1. Regresi Logistik Sederhana

   Regresi logistik sederhana digunakan untuk memodelkan hubungan antara satu variabel independen (X) dan variabel dependen (Y), yang merupakan variabel kategorik (contohnya: sukses/gagal). Fungsi logit digunakan untuk memetakan peluang (π(x)) menjadi bilangan antara $-\infty$ dan $+\infty$:

$$\log i\, t\big(\pi(x)\big) = \log\left(\frac{\pi(x)}{1-\pi(x)}\right) = \alpha + \beta x$$

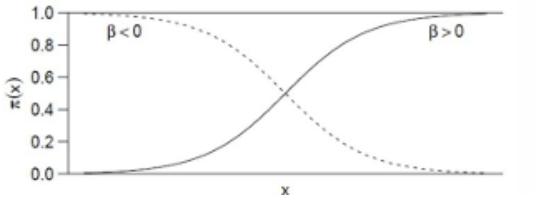
   Dengan;

   - π(x):
   - α: Intersep (nilai logit saat x=0).

- β: Koefisien yang menunjukkan pengaruh perubahan x terhadap logit atau odds.

Dan peluang kesuksesan dihitung dengan:

$$\pi(x) = \frac{e^{\alpha+\beta x}}{1 + e^{\alpha+\beta x}}$$



Gambar 1. Grafik Kurva Regresi logistik

- Jika $\beta = 0$ maka $\pi(x) = \frac{e^{\alpha}}{1+e^{\alpha}}$ tidak berubah terhadap x
- Jika $|\beta|$ >> maka kurva akan naik/turun curam
- Titik simetris

$$\pi(x) = 1/2 \iff e^{\alpha+\beta x} = 1 = e^{0}$$
$$\iff \alpha + \beta x = 0 \iff x = -\alpha/\beta.$$

2. Regresi Logistik Berganda

Model regresi logistik berganda adalah perpanjangan dari regresi logistik sederhana untuk menangani beberapa variabel independen. Model ini digunakan untuk memprediksi peluang kejadian biner (π=P(Y=1)) berdasarkan kombinasi variabel-variabel prediktor, baik kontinu maupun kategorik.

- Variabel dependent (Y): dikotomus/binary, $\pi = P(Y = 1)$
- Varibel independent (X): kontinu atau kategorik (dummy)

Persamaan model:

$$\log i\, t(\pi) = \log\left(\frac{\pi}{1-\pi}\right) = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k$$

Atau

$$\pi(x) = \frac{e^{\alpha+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k}}{1 + e^{\alpha+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_k x_k}}$$

- β_i adalah efek parsial dari x_i dengan mengontrol variabel prediktor lainnya di dalam model
- e^{β_i} adalah odds ratio pada $x_i + 1$ vs x_i dengan mengasumsikan variabel lain konstan di dalam model (jika X variabel kontinu)

C. Seleksi Variabel

Seleksi variabel dilakukan sebagai dasar untuk membuat model. Dalam penelitian ini uji independen t dan chisquare dipakai untuk melihat signifikansi setiap variabel prediktor terhadap variabel respon ‘left’. Uji t digunakan untuk untuk melihat signifikansi variabel numerik dan uji chisquare digunakan untuk melihat signifikansi variabel kategorik. Jika hubungan antara variabel respon dan variabel prediktor dengan uji parsial menunjukkan angka p-value kurang dari 0,05 maka variabel prediktor tersebut signifikan dan akan dimasukkan ke dalam model. Berikut merupakan hasil dari uji t dan uji chisquare;

- Hasil uji chisquare;

```
=== Uji Chi-Square untuk variabel kategorik ===
Uji Chi-Square antara 'left' dan salary_encoded

        Pearson's Chi-squared test

data:  table(HR$left, HR[[var]])
X-squared = 381.23, df = 2, p-value < 2.2e-16


--------------------------------------
Uji Chi-Square antara 'left' dan sales_encoded

        Pearson's Chi-squared test

data:  table(HR$left, HR[[var]])
X-squared = 86.825, df = 9, p-value = 7.042e-15


--------------------------------------
```

Gambar 2. Hasil Uji Chi-Square untuk variabel kategorik (salary encode dan sales_encoded)

```
--------------------------------------
Uji Chi-Square antara 'left' dan Work_accident

        Pearson's Chi-squared test with Yates' continuity correction

data:  table(HR$left, HR[[var]])
X-squared = 357.56, df = 1, p-value < 2.2e-16


--------------------------------------
Uji Chi-Square antara 'left' dan promotion_last_5years

        Pearson's Chi-squared test with Yates' continuity correction

data:  table(HR$left, HR[[var]])
X-squared = 56.262, df = 1, p-value = 6.344e-14


--------------------------------------
```

Gambar 3. Hasil Uji Chi-Square untuk variabel kategorik (work_accident dan promotion_last_5years)

- Hasil uji t untuk variabel numerik:

```
=== Uji t-Test untuk variabel numerik ===
Uji t-Test antara 'left' dan satisfaction_level

        Welch Two Sample t-test

data:  HR[[var]] by HR$left
t = 46.636, df = 5167, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 0.2171815 0.2362417
sample estimates:
mean in group 0 mean in group 1
      0.6668096       0.4400980
```

Gambar 4. Hasil uji t untuk variabel satisfaction_level

```
-------------------------------------
Uji t-Test antara 'left' dan last_evaluation

        Welch Two Sample t-test

data:  HR[[var]] by HR$left
t = -0.72534, df = 5154.9, p-value = 0.4683
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -0.009772224  0.004493874
sample estimates:
mean in group 0 mean in group 1
      0.7154734       0.7181126
```

Gambar 5. Hasil uji t untuk variabel last_evaluation

```
-------------------------------------
Uji t-Test antara 'left' dan average_montly_hours

        Welch Two Sample t-test

data:  HR[[var]] by HR$left
t = -7.5323, df = 4875.1, p-value = 5.907e-14
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -10.534631  -6.183384
sample estimates:
mean in group 0 mean in group 1
       199.0602        207.4192
```

Gambar 6. Hasil uji t untuk variabel average_monthly_hours

```
-------------------------------------
Uji t-Test antara 'left' dan number_project

        Welch Two Sample t-test

data:  HR[[var]] by HR$left
t = -2.1663, df = 4236.5, p-value = 0.03034
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -0.131136535 -0.006540119
sample estimates:
mean in group 0 mean in group 1
       3.786664        3.855503
```

Gambar 7. Hasil uji t unuk variabel number_project

```
-------------------------------------
Uji t-Test antara 'left' dan time_spend_company

        Welch Two Sample t-test

data:  HR[[var]] by HR$left
t = -22.631, df = 9625.6, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -0.5394767 -0.4534706
sample estimates:
mean in group 0 mean in group 1
       3.380032        3.876505

-------------------------------------
```

Gambar 8. Hasil uji t unuk variabel time_spend_company

Dari gambar uji t dan chi square di atas bisa dillihat bahwa variabel prediktor (independen) 'last_evaluation' tidak signifikan karena lebih dari 0,05 sehingga tidak akan dimasukkan dalam model. Kemudian setelah dilakukan uji-t dan uji chi-square akan dilihat uji *wald* untuk melihat apakah masih terdapat variabel yang tidak signifikan setelah dilakukan penghapusan variabel last_evaluation.

```
Call:
glm(formula = left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + Work_accident + promotion_last_5years +
    sales_encoded + salary_encoded, family = binomial, data = HR)

Coefficients:
                      Estimate Std. Error z value Pr(>|z|)
(Intercept)           1.3264090  0.1351947   9.811  < 2e-16 ***
satisfaction_level   -4.0275309  0.0947475 -42.508  < 2e-16 ***
number_project       -0.2792259  0.0199439 -14.001  < 2e-16 ***
average_montly_hours  0.0050418  0.0004978  10.129  < 2e-16 ***
time_spend_company    0.2620140  0.0151526  17.292  < 2e-16 ***
Work_accident        -1.5367549  0.0893444 -17.200  < 2e-16 ***
promotion_last_5years -1.5237394  0.2557366  -5.958 2.55e-09 ***
sales_encoded         0.0117468  0.0079653   1.475     0.14
salary_encoded       -0.7043002  0.0378095 -18.628  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 16465  on 14998  degrees of freedom
Residual deviance: 12976  on 14990  degrees of freedom
AIC: 12994

Number of Fisher Scoring iterations: 5
```

Gambar 9. Hasil Uji Wald Semua Variabel

Dari gambar hasil diperoleh bahwa p-value sales_encoded > 0.05 sehingga akan dilakukan penghapusan variabel sales_encoded dari model.

Jadi, variabel prediktor (independen) yang signifikan terhadap respon (depensent) *left* adalah *satisfaction_level, number_project, average_montly_hours, time_spend_company, Work_accident, Work_accident, promotion_last_5years, dan salary_encoded.* Sehingga, variabel-variabel tersebut akan digunakan untuk membangun asumsi model regresi logistik

D. Membangun Model

Pembangunan model regresi adalah proses penting dalam analisis data untuk memprediksi variabel respon (dependen) berdasarkan satu atau lebih variabel prediktor (independen). Pembangunan model bertujuan untuk mencari subset kandidat prediktor yang menghasilkan model regresi yang sederhana tetapi bermanfaat.

a. Model Asumsi

Model regresi yang diasumsikan untuk penelitian ini adalah sebagai berikut:

1. **Model tanpa Interaksi**

$\text{logit}(\pi) = \beta_0 + \beta_1 \text{satisfaction_level} + \beta_2 \text{number_project} + \beta_3 \text{average_montly_hours} + \beta_4 \text{time_spend_company} + \beta_5 \text{as.factor(Work_accident)} + \beta_6 \text{as.factor(promotion_last_5years)} + \beta_7 \text{as.factor(salary_encoded)}$

2. **Model dengan Interaksi**

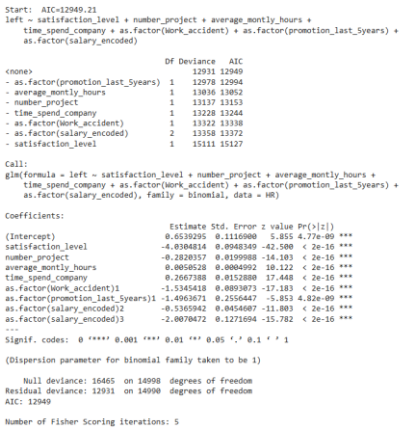
$\text{logit}(\pi) = \beta_0 + \beta_1 \text{satisfaction_level} + \beta_2 \text{number_project} + \beta_3 \text{average_montly_hours} + \beta_4 \text{time_spend_company} + \beta_5 \text{as.factor(Work_accident)} + \beta_6 \text{as.factor(promotion_last_5years)} + \beta_7 \text{as.factor(salary_encoded)} + \beta_8 \text{as.factor(salary_encoded)*as.factor(promotion_last_5years)} + \beta_9 \text{satisfication_level} * \text{as.factor(salary_encoded)} + \beta_{10} \text{time_spend_company*as.factor(promotion_last_5years)} + \beta_{11} \text{satisfication_level} * \text{average_monthly_hours}$

b. Seleksi Model

Dari model tanpa interaksi dan model dengan interaksi dilakukan Eliminasi Backward untuk mencari model terbaik dengan menggunakan *Stepwise regression* eliminasi backward.

Stepwise regression eliminasi backward merupakan langkah mundur dengan meregresikan semua variabel prediktor dengan variabel respon, Eliminasi dilakukan terhadap variabel prediktor yang memiliki nilai signifikansi yang lebih dari taraf 0.05.

a. Model Tanpa Interaksi



```
Start:  AIC=12949.21
left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + as.factor(Work_accident) + as.factor(promotion_last_5years) +
    as.factor(salary_encoded)

                                Df Deviance   AIC
<none>                               12931 12949
- as.factor(promotion_last_5years)  1    12978 12994
- average_montly_hours              1    13036 13052
- number_project                    1    13137 13153
- time_spend_company                1    13228 13244
- as.factor(Work_accident)          1    13322 13338
- as.factor(salary_encoded)         2    13358 13372
- satisfaction_level                1    15111 15127

Call:
glm(formula = left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + as.factor(Work_accident) + as.factor(promotion_last_5years) +
    as.factor(salary_encoded), family = binomial, data = HR)

Coefficients:
                                 Estimate Std. Error z value Pr(>|z|)
(Intercept)                     0.6539295  0.1116900   5.855 4.77e-09 ***
satisfaction_level             -4.0304814  0.0948349 -42.500  < 2e-16 ***
number_project                 -0.2820357  0.0199988 -14.103  < 2e-16 ***
average_montly_hours            0.0050528  0.0004992  10.122  < 2e-16 ***
time_spend_company              0.2667388  0.0152880  17.448  < 2e-16 ***
as.factor(Work_accident)1      -1.5345418  0.0893073 -17.183  < 2e-16 ***
as.factor(promotion_last_5years)1 -1.4963671  0.2556447  -5.853 4.82e-09 ***
as.factor(salary_encoded)2     -0.5365942  0.0454607 -11.803  < 2e-16 ***
as.factor(salary_encoded)3     -2.0070472  0.1271694 -15.782  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

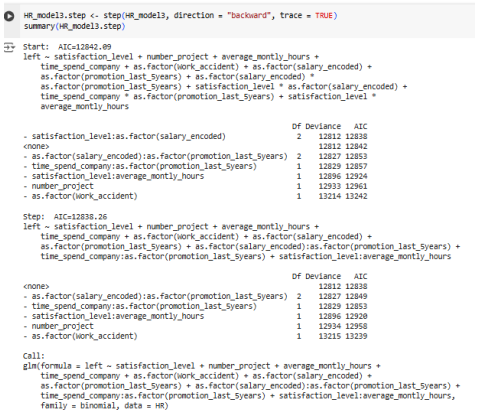
(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 16465  on 14998  degrees of freedom
Residual deviance: 12931  on 14990  degrees of freedom
AIC: 12949

Number of Fisher Scoring iterations: 5
```

Gambar 10. Hasil *Stepwise* "*Backward*" model tanpa interaksi

b. Model dengan Interaksi



```
HR_model3.step <- step(HR_model3, direction = "backward", trace = TRUE)
summary(HR_model3.step)

Start:  AIC=12842.09
left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + as.factor(Work_accident) + as.factor(salary_encoded) +
    as.factor(promotion_last_5years) + as.factor(salary_encoded) *
    as.factor(promotion_last_5years) + satisfaction_level * as.factor(salary_encoded) +
    time_spend_company * as.factor(promotion_last_5years) + satisfaction_level *
    average_montly_hours

                                                      Df Deviance   AIC
- satisfaction_level:as.factor(salary_encoded)         2    12812 12838
<none>                                                      12812 12842
- as.factor(salary_encoded):as.factor(promotion_last_5years)  2    12827 12853
- time_spend_company:as.factor(promotion_last_5years)         1    12829 12857
- satisfaction_level:average_montly_hours                     1    12896 12924
- number_project                                              1    12933 12961
- as.factor(Work_accident)                                    1    13214 13242

Step:  AIC=12838.26
left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + as.factor(Work_accident) + as.factor(salary_encoded) +
    as.factor(promotion_last_5years) + as.factor(salary_encoded):as.factor(promotion_last_5years) +
    time_spend_company:as.factor(promotion_last_5years) + satisfaction_level:average_montly_hours

                                                      Df Deviance   AIC
<none>                                                      12812 12838
- as.factor(salary_encoded):as.factor(promotion_last_5years)  2    12827 12849
- time_spend_company:as.factor(promotion_last_5years)         1    12829 12853
- satisfaction_level:average_montly_hours                     1    12896 12920
- number_project                                              1    12934 12958
- as.factor(Work_accident)                                    1    13215 13239

Call:
glm(formula = left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + as.factor(Work_accident) + as.factor(salary_encoded) +
    as.factor(promotion_last_5years) + as.factor(salary_encoded):as.factor(promotion_last_5years) +
    time_spend_company:as.factor(promotion_last_5years) + satisfaction_level:average_montly_hours,
    family = binomial, data = HR)
```

Gambar 11. Hasil *Stepwise* "*Backward*" model dengan interaksi

c. Pemilihan Model Terbaik

Dari hasil eliminasi backward pada kedua model tersebut akan dilakukan uji anova untuk mendapatkan model yang terbaik.

H_0: Model tanpa interaksi lebih baik

H_1: Model dengan interaksi lebih baik

A anova: 2 × 5

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	14990	12931.21	NA	NA	NA
2	14986	12812.26	4	118.9517	8.944196e-25

Gambar 12. Hasil Uji Anova
(model dengan interaksi dan model tanpa interaksi)

Berdasarkan hasil dari uji anova diatas, diperoleh p-value sebesar $8.944196e^{-25}$ dimana lebih kecil dari $\alpha = 0.05$, artinya tolak H_0 $(terima\ H_1)$ maka dapat disimpulkan bahwa model dengan interaksi lebih baik.

3. HASIL DAN PEMBAHASAN

1. Uji Hosmer Lemeshow

Uji Hosmer-Lemeshow adalah metode statistik yang digunakan untukmenilai goodness-of-fit atau kesesuaian model regresi logistik dengan data empiris. Hipotesis yang digunakan pada uji Hosmer-Lemeshow adalah sebagai berikut:

H_0: Model fit dengan data

H_1: Model tidak fit dengan data

```
        Hosmer and Lemeshow goodness of fit (GOF) test

data:  HR$left, fitted(HR_model4.step)
X-squared = 502.01, df = 8, p-value < 2.2e-16
```

Gambar 13. Hasil Uji Hosmer-Lemeshow

Berdasarkan hasil uji hosmer lemeshow diatas, diperoleh p-value sebesar 2.2e-16 < 0.05, artinya tolak H_0. Maka, dapat disimpulkan bahwa model tidak fit dengan data.

2. Uji Klasifikasi

Uji klasifikasi adalah metode untuk mengevaluasi performa model klasifikasi dalam memprediksi kategori atau kelas berdasarkan data input. Model klasifikasi mencoba memetakan input menjadi kelas atau kategori, biasanya berupa variabel biner seperti dalam penelitian ini, yaitu 0 yang mendikasi karyawan tidak mengundurkan diri (tidak left) atau 1 karyawan mengundurkan diri (left). Evaluasi model dilakukan dengan membandingkan prediksi model dengan data aktual (observasi sebenarnya). Dari penelitian ini didapat tabel klasifikasi seperti gambar di bawah.

```
   Cell Contents
|-------------------------|
|                       N |
|-------------------------|


Total Observations in Table:  14999


                     | Observed
Predicted (cut = .50) |         0 |         1 | Row Total |
----------------------|-----------|-----------|-----------|
                    0 |     10496 |      2209 |     12705 |
----------------------|-----------|-----------|-----------|
                    1 |       932 |      1362 |      2294 |
----------------------|-----------|-----------|-----------|
         Column Total |     11428 |      3571 |     14999 |
----------------------|-----------|-----------|-----------|
```

Gambar 14. Hasil Uji Klasifikasi

Baris tabel menyatakan prediksi model (hasil dari model klasifikasi), sedangkan kolom menyatakan observasi sebenarnya (data aktual). Jadi kita bisa mendapat informasi data dari tabel yaitu;

- Total data obeservasi = 14.999
- True Negative (TN) = 10.496
- False Positive (FP) = 932
- False Negative (FN) = 2.209
- True Positive (TP) = 1.362

Berdasarkan informasi di atas, akurasi model dapat dihitung dengan rumus berikut:

$$Akurasi = \frac{TN+TP}{Total\ Observasi}$$

$$Akurasi = \frac{10496 + 1362}{14999} = 0{,}791 = 79{,}1\%$$

Artinya, model klasifikasi ini memiliki akurasi 79.1%, yang berarti cukup baik dalam memprediksi apakah karyawan akan mengundurkan diri (left) atau tidak mengundurkan diri (tidak left). Kemudian dapat dicari nilai error pada tabel kontingensi dengan rumus sebagai berikut.

$$Error = 1 - Akurasi = 20{,}9\%$$

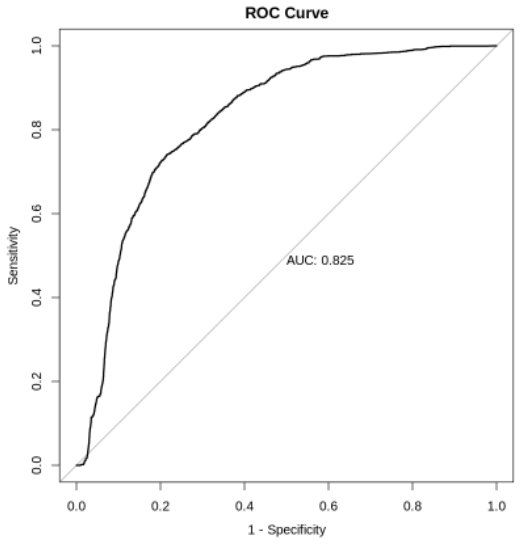
3. Uji Kurva ROC

Kurva ROC merupakan hasil plot *sensitivity* dan *1-specificity* pada keseluruhan rentang titik cut-off yang mungkin. Kurva ROC banyak digunakan untuk menggambarkan keakuratan model dan menentukan nilai cut-off yang optimal area di bawah kurva ROC adalah nol sampai satu.

Luas area di bawah kurva mampu mengukur seberapa besar kemampuan model untuk mendiskriminasi observasi yang mengalami kejadian sukses dan tidak mengalami kejadian sukses. Biasanya kurva ROC berbentuk cekung yang menghubungkan antara titik (0,0) dan titik (1,1).

Kategori hasil luas area di bawah kurva ROC menurut Kleinbaum & Klein (2010) sebagai berikut:

- 0,9 < luas area di bawah kurva ROC ≤ 1,0 = Excellent discrimination
- 0,8 < luas area di bawah kurva ROC ≤ 0,9 = Good discrimination
- 0,7 < luas area di bawah kurva ROC ≤ 0,8 = Fair discrimination
- 0,6 < luas area di bawah kurva ROC ≤ 0,7 = Poor discrimination
- 0,5 < luas area di bawah kurva ROC ≤ 0,6 = Failed discrimination

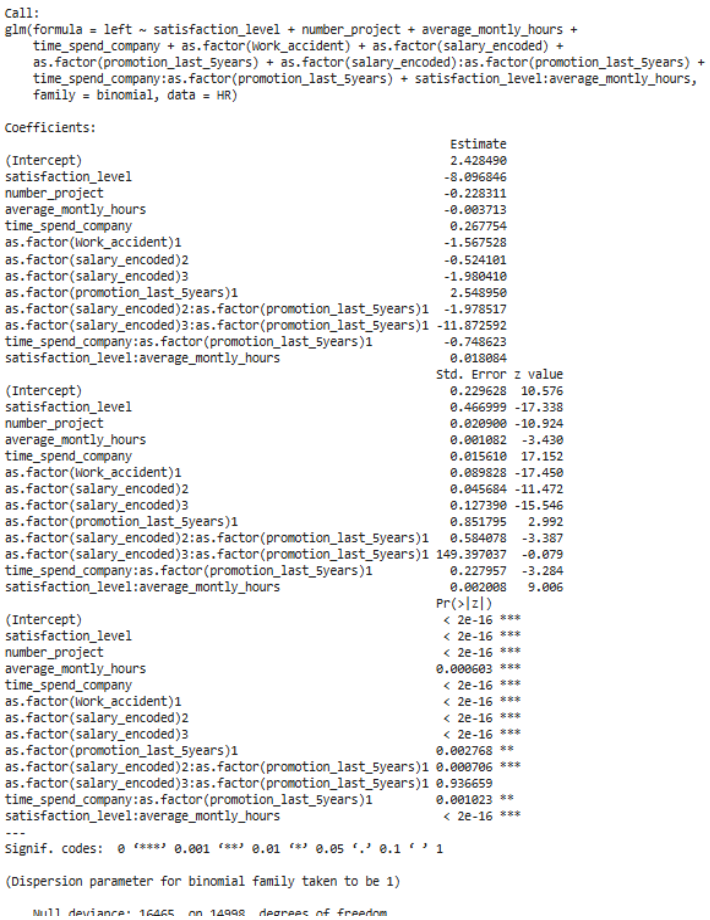


Gambar 15. hasil kurva ROC

Berdasarkan gambar kurva ROC diatas didapat luas daerah dibawah kurva-ROC atau diperoleh nilai AUC sebesar 0.825 yang berarti bahwa model dapat mendiskriminasi data dengan baik.

4. Model Terbaik

Dari hasil seleksi model dan uji anova terhadap model dengan interaksi dan tanpa interaksi didapat model terbaik



```
Call:
glm(formula = left ~ satisfaction_level + number_project + average_montly_hours +
    time_spend_company + as.factor(Work_accident) + as.factor(salary_encoded) +
    as.factor(promotion_last_5years) + as.factor(salary_encoded):as.factor(promotion_last_5years) +
    time_spend_company:as.factor(promotion_last_5years) + satisfaction_level:average_montly_hours,
    family = binomial, data = HR)

Coefficients:
                                                        Estimate
(Intercept)                                             2.428490
satisfaction_level                                     -8.096846
number_project                                         -0.228311
average_montly_hours                                   -0.003713
time_spend_company                                      0.267754
as.factor(Work_accident)1                              -1.567528
as.factor(salary_encoded)2                             -0.524101
as.factor(salary_encoded)3                             -1.980410
as.factor(promotion_last_5years)1                       2.548950
as.factor(salary_encoded)2:as.factor(promotion_last_5years)1  -1.978517
as.factor(salary_encoded)3:as.factor(promotion_last_5years)1 -11.872592
time_spend_company:as.factor(promotion_last_5years)1   -0.748623
satisfaction_level:average_montly_hours                 0.018084
                                                       Std. Error z value
(Intercept)                                              0.229628  10.576
satisfaction_level                                       0.466999 -17.338
number_project                                           0.020900 -10.924
average_montly_hours                                     0.001082  -3.430
time_spend_company                                       0.015610  17.152
as.factor(Work_accident)1                                0.089828 -17.450
as.factor(salary_encoded)2                               0.045684 -11.472
as.factor(salary_encoded)3                               0.127390 -15.546
as.factor(promotion_last_5years)1                        0.851795   2.992
as.factor(salary_encoded)2:as.factor(promotion_last_5years)1   0.584078  -3.387
as.factor(salary_encoded)3:as.factor(promotion_last_5years)1 149.397037  -0.079
time_spend_company:as.factor(promotion_last_5years)1     0.227957  -3.284
satisfaction_level:average_montly_hours                  0.002008   9.006
                                                        Pr(>|z|)
(Intercept)                                              < 2e-16 ***
satisfaction_level                                       < 2e-16 ***
number_project                                           < 2e-16 ***
average_montly_hours                                    0.000603 ***
time_spend_company                                       < 2e-16 ***
as.factor(Work_accident)1                                < 2e-16 ***
as.factor(salary_encoded)2                               < 2e-16 ***
as.factor(salary_encoded)3                               < 2e-16 ***
as.factor(promotion_last_5years)1                       0.002768 **
as.factor(salary_encoded)2:as.factor(promotion_last_5years)1 0.000706 ***
as.factor(salary_encoded)3:as.factor(promotion_last_5years)1 0.936659
time_spend_company:as.factor(promotion_last_5years)1    0.001023 **
satisfaction_level:average_montly_hours                  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 16465  on 14998  degrees of freedom
```

Gambar 16. Model Terbaik

Persamaan model regresi logistik yang akan terbentuk adalah sebagai berikut:

$$\text{logit}(\pi) = \alpha + \beta_2 \text{satisfaction_level} + \beta_3 \text{number_project} + \beta_4 \text{average_montly_hours} + \beta_5 \text{time_spend_company} + \beta_6 \text{Work_accident1} + \beta_7 \text{salary_encoded2} + \beta_8 \text{salary_encoded3} + \beta_9 \text{promotion_last_5years1} + \gamma_2 \text{salary_encoded2} * \text{promotion_last_5years1} + \gamma_3 \text{salary_encoded3} * \text{promotion_last_5years1} + \gamma_3 \text{time_spend_company} * \text{promotion_last_5years1} + \gamma_4 \text{satisfaction_level*average_monthly_hours}$$

Persamaan regresi logistik dapat dituliskan dengan koefisien regresi pada masing-masing variabel seperti berikut:

$$\text{logit}(\pi) = 2.428490 + (-8.096846)\text{satisfaction_level}$$
$$+ (-0.228311)\text{number_project} + (-0.003713)\text{average_montly_hours}$$
$$+ 0.267754\ \text{time_spend_company} + (-1.567528)\text{Work_accident1}$$
$$+ (-0.524101)\text{salary_encoded2}$$
$$+ (-1.980410)\text{salary_encoded3} + 2.548950\ \text{promotion_last_5years1}$$
$$+ (-1.978517)\text{salary_encoded2} * \text{promotion_last_5years1}$$
$$+ (-11.872592)\text{salary_encoded3} * \text{promotion_last_5years1}$$
$$+ (-0.748623)\text{time_spend_company} * \text{promotion_last_5years1}$$
$$+ 0.018084\ \text{satisfaction_level*average_monthly_hours}$$

5. Interpretasi Model

β2: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-8,096846} \approx 0.0003$ untuk setiap peningkatan satu unit dalam tingkat kepuasan karyawan.

β3: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-0.228311} \approx 0.796$ untuk setiap tambahan satu proyek.

β4: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-0.003713} \approx 0.996$ untuk setiap tambahan satu jam kerja rata-rata bulanan.

β5: Estimasi odds mengundurkan diri (left) meningkat sebesar $e^{0.267754} \approx 1.307$ untuk setiap peningkatan satu tahun masa kerja.

β6: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-1.567528} \approx 0.209$ untuk karyawan yang mengalami kecelakaan kerja dibandingkan dengang tidak.

β7: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-0.524101} \approx 0.592$ untuk karyawan dengan gaji menengah dibandingkan dengan referensi (gaji rendah).

β8: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-1.980410} \approx 0.138$ untuk karyawan dengan gaji tinggi dibandingkan dengan referensi (gaji rendah).

β9: Estimasi odds mengundurkan diri (left) meningkat sebesar $e^{2.548950} \approx 12.784$ untuk karyawan yang mendapatkan promosi dalam 5 tahun terakhir dibandingkan dengan yang tidak.

β10: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-1.978517} \approx 0.138$ untuk karyawan dengan gaji menengah yang mendapatkan promosi dibandingkan dengan karyawan gaji rendah yang mendapatkan promosi.

β11: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-11.872592} \approx 6.97 \times 10^{-6}$ untuk karyawan dengan gaji tinggi yang mendapatkan promosi dibandingkan dengan karyawan gaji rendah yang mendapatkan promosi.

β12: Estimasi odds mengundurkan diri (left) menurun sebesar $e^{-0.748623} \approx 0.473$ untuk setiap tambahan satu tahun masa kerja karyawan yang mendapatkan promosi.

β13: Estimasi odds mengundurkan diri (left) meningkat sebesar $e^{0.018084} \approx 1.018$ untuk setiap peningkatan dalam interaksi antara tingkat kepuasan dan rata-rata jam kerja bulanan.

4. KESIMPULAN

Berdasarkan hasil dan pembahasan yang telah dilakukan, dapat disimpulkan bahwa persamaan logistik model adalah sebagai berikut:

$$\begin{aligned}\text{logit}(\pi) = {} & 2.428490 + (-8.096846)\text{satisfaction_level} \\ & + (-0.228311)\text{number_project} \\ & + (-0.003713)\text{average_montly_hours} \\ & + 0.267754\ \text{time_spend_company} + (-1.567528)\text{Work_accident1} \\ & + (-0.524101)\text{salary_encoded2} \\ & + (-1.980410)\text{salary_encoded3} + 2.548950\ \text{promotion_last_5years1} \\ & + (-1.978517)\text{salary_encoded2} * \text{promotion_last_5years1} \\ & + (-11.872592)\text{salary_encoded3} * \text{promotion_last_5years1} \\ & + (-0.748623)\text{time_spend_company} * \text{promotion_last_5years1} \\ & + 0.018084\ \text{satisfaction_level*average_monthly_hours}\end{aligned}$$

Dengan akurasi sebesar 79.1%, dan error sebesar 20,9% bisa dikatakan bahwa model cukup baik. AUC sebesar 0.825 juga menunjukkan bahwa model dapat mendiskriminasi model dengan baik. Dari model di atas pula diketahui faktor-faktor yang mempengaruhi peningkatan pengunduran diri karyawan yaitu, masa kerja yang lebih lama (time_spend_company) dan promosi dalam 5 tahun terakhir (promotion_last_5years). Sedangkan faktor-faktor yang menurunkan kemungkinan mengundurkan diri adalah tingkat kepuasan karyawan (satisfaction_level), jumlah proyek (number_project), kecelakaan kerja (Work_accident), gaji yang lebih tinggi

(salary), dan tahun masa kerja karyawan yang mendapatkan promosi (time_spend_company ∗ promotion_last_5years).

Referensi

Nurrizqi, A. I., Erfiani, Indahwati, Fitrianto, A., & Amelia, R. (2022). Pemodelan regresi logistik berbasis backward elimination untuk mengetahui faktor yang memengaruhi tingkat kemiskinan di Indonesia tahun 2021. Jurnal Statistika dan Aplikasinya, 6(2), 160–170.

Nur M.R.F, Oktora S.I. (2020). Analisis kurva ROC pada model logit dalam pemodelan determinan lansia bekerja di kawasan Timur Indonesia. *Indonesian Journal of Statistics and Applications.* 4(1), 116-135.

"Classification Table." Real Statistics Using Excel, https://real--statistics-com.translate.goog/logistic-regression/classification-table/?_x_tr_sl=en&_x_tr_tl=id&_x_tr_hl=id&_x_tr_pto=tc. Diakses pada 20 Desember 2024

Appendiks

```
Install Package
library(dplyr)

install.packages('car') # Install the car package
library(car) # Load the car package

# Install the gmodels package
install.packages("gmodels")

# Load the gmodels package
library(gmodels)

install.packages("pROC")
library(pROC)

install.packages("ResourceSelection")
library(ResourceSelection)

Loading Data
url <- "https://raw.githubusercontent.com/Miyaputri/ADK/main/HR.csv"
HR <- read.csv(url)
head(HR)

Preprocessing
summary(HR)

# Cek tipe data
str(HR)

# Ordinal encoding untuk salary (misalnya berdasarkan urutan tertentu)
HR$salary <- factor(HR$salary, levels = c("low", "medium", "high"), ordered =
TRUE)
HR$salary_encoded <- as.numeric(HR$salary)
HR$salary_encoded

# Mengubah variabel sales dari kategorik menjadi numerik
HR$sales_encoded <- as.numeric(factor(HR$sales))
HR$sales_encoded

#menghapus variabel sales dan salary
HR <- HR %>% dplyr::select(-sales, -salary)
head(HR)

str(HR)
```

```r
# Uji Chi-Square untuk variabel kategorik
cat("=== Uji Chi-Square untuk variabel kategorik ===\n")

# Variabel kategorik
categorical_vars <- c("salary_encoded", "sales_encoded", "Work_accident",
"promotion_last_5years")

for (var in categorical_vars) {
  cat("Uji Chi-Square antara 'left' dan", var, "\n")
  chisq_res <- chisq.test(table(HR$left, HR[[var]])) # Tabel kontingensi
  print(chisq_res)
  cat("\n--------------------------------------\n")
}

# Uji t-Test untuk variabel numerik
cat("\n=== Uji t-Test untuk variabel numerik ===\n")

# Variabel numerik
numeric_vars <- c("satisfaction_level", "last_evaluation",
                  "number_project",                    "average_montly_hours",
"time_spend_company")

for (var in numeric_vars) {
  cat("Uji t-Test antara 'left' dan", var, "\n")
  ttest_res <- t.test(HR[[var]] ~ HR$left)
  print(ttest_res)
  cat("\n--------------------------------------\n")
}

Model
HR_model<-glm(formula = left ~ satisfaction_level + number_project +
average_montly_hours + time_spend_company+ Work_accident +
promotion_last_5years + sales_encoded + salary_encoded,data = HR,
family=binomial)
summary(HR_model)

HR_model1 <-glm(formula = left ~ satisfaction_level + number_project +
average_montly_hours + time_spend_company+ Work_accident +
promotion_last_5years + salary_encoded,data = HR, family=binomial)
summary(HR_model)

# cek multikolinearitas model sebelum model asumsi
vif(HR_model1)

HR_model2<-glm(formula = left ~ satisfaction_level + number_project +
average_montly_hours + time_spend_company+
```

```r
as.factor(Work_accident)+as.factor(promotion_last_5years)+as.factor(salary_enc
oded),data = HR, family=binomial)
summary(HR_model2)

# cek multikolinearitas model sebelum model asumsi
vif(HR_model2)

anova(HR_model1, HR_model2, test = "Chisq")

Asumsi Model dengan Interaksi
HR_model3 <- glm(
  formula = left ~ satisfaction_level +
    number_project +
    average_montly_hours +
    time_spend_company +
    as.factor(Work_accident) +
    as.factor(salary_encoded)+
    as.factor(promotion_last_5years) +
    as.factor(salary_encoded) * as.factor(promotion_last_5years) +
    satisfaction_level * as.factor(salary_encoded) +
    time_spend_company * as.factor(promotion_last_5years) +
    satisfaction_level * average_montly_hours,
  data = HR,
  family = binomial
)



summary(HR_model3)

vif(HR_model3)

HR_model2.step <- step(HR_model2, direction = "backward", trace = TRUE)
summary(HR_model2.step)

HR_model3.step <- step(HR_model3, direction = "backward", trace = TRUE)
summary(HR_model3.step)

Model Terbaik
anova(HR_model2.step, HR_model3.step, test = "Chisq")

summary(HR_model3.step)

HR_model3.step.hs <- hoslem.test(HR$left, fitted(HR_model3.step),g = 10)
HR_model3.step.hs

yhat <- fitted(HR_model3.step)  # Mendapatkan prediksi peluang
pred_50 <- ifelse(yhat >= 0.50, 1, 0)  # Prediksi 0/1, dengan threshold 0.50
```

```r
# Membuat dataframe untuk membandingkan prediksi dan data asli
classify <- as.data.frame(cbind(pred_50, case = HR$left))  # Prediksi dan data asli

# Menampilkan tabel klasifikasi menggunakan CrossTable
CrossTable(classify$pred_50, classify$case,
           dnn = c("Predicted (cut = .50)", "Observed"),
           format = "SAS",
           prop.r = FALSE, prop.c = FALSE, prop.t = FALSE,
           prop.chisq = FALSE, chisq = FALSE, fisher = FALSE)

# Hitung probabilitas prediksi untuk model
yhat <- fitted(HR_model3.step)

# Membuat ROC curve
roc1 <- roc(HR$left, yhat)

# Plot ROC curve
plot.roc(roc1, main = "ROC Curve", print.auc = TRUE, legacy.axes = TRUE)

Model Terbaik
summary(HR_model3.step)
```